

# Практическая работа №3. Свёрточные нейронные сети

Работу выполнил:

Мовчан Игорь, 368540

## Классификация цветов с помощью свёрточных нейронных сетей.

В работе необходимо познакомится с различными архитектурами сверхточных нейронных сетей и их обучением на GPU (англ. graphics processing, графический процессор) на языке программирования Python 3 и фреймворка Torch (PyTorch). Для этого предлагается использовать ресурсы Google Colab - Colaboratory, для выполнения вычислений на GPU. После ознакомления, выполнить практическое задание в конце данной тетради (notebook).

Рассмотрим [Датасет](#) содержащий 4322 изображения цветов размеченных по 5 видам (тюльпан, ромашка, подсолнух, роза, одуванчик). Данный набор данных можно скачать по [ссылке](#) с сайте kaggle.

Загрузите папку с картинками на гугл диск, чтобы не загружать ее каждый раз заново при перезапуске колаба. Структура файлов (можно посмотреть в меню слева) может быть такой: "/content/drive/My Drive/data/flowers".

Обязательно подключите аппаратный ускоритель (GPU) к среде выполнения. В меню сверху: Среда выполнения -> Сменить среду выполнения

Первым делом разберите более детально код выполнив код ниже.

## Подготовка

Загружаем библиотеки. Фиксируем random.seed для воспроизводимости

```
import numpy as np
import os
import torch
import torchvision
from torchvision.datasets.utils import download_url
from torch.utils.data import random_split
from torchvision.datasets import ImageFolder
from torchvision import transforms
from torchvision.transforms import ToTensor
from torch.utils.data.dataloader import DataLoader
```

```
import torch.nn as nn
import torch.nn.functional as F
import pandas as pd
import random
from tqdm import tqdm
import matplotlib.pyplot as plt

random.seed(0)
torch.manual_seed(0)

<torch._C.Generator at 0x7f8060f9fe50>
```

Выбираем на чем будем делать вычисления - CPU или GPU (cuda)

```
device = 'cuda' if torch.cuda.is_available() else 'cpu'
print(device)

cuda
```

Блок для соединения с Google Colab

```
from google.colab import drive

drive.mount('/content/drive', force_remount=True)

FOLDERNAME = 'data/flowers'

%cd drive/My\ Drive
#%cp -r $FOLDERNAME ../../
#%cd ../../
%cd data/flowers/
#!bash get_datasets.sh
#%cd ../../

#+For kaggle
# for dirname, _, filenames in os.walk('/kaggle/input'):
#     for filename in filenames:
#         print(os.path.join(dirname, filename))
# FOLDERNAME = '/kaggle/input/flowers-recognition/flowers'
# %cd /kaggle/input/flowers-recognition/flowers

Mounted at /content/drive
/content/drive/My Drive
/content/drive/My Drive/data/flowers

prepare_imgs = torchvision.transforms.Compose(
    [
        torchvision.transforms.Resize((224, 224)), #приводим картинки
        к одному размеру
        torchvision.transforms.ToTensor(), # упаковываем их в тензор
```

```

        torchvision.transforms.Normalize(
            mean=[0.485, 0.456, 0.406], std=[0.229, 0.224, 0.225] # 
нормализуем картинки по каналам
        ),
    ]
)
# задаем датасет. Лейблы - имена папок:
dataset = ImageFolder('/content/drive/My Drive/data/flowers',
transform=prepare_imgs)

dataset.imgs[2]
('/content/drive/My
Drive/data/flowers/daisy/10172379554_b296050f82_n.jpg', 0)

class ValueMeter(object):
"""
Вспомогательный класс, чтобы отслеживать loss и метрику
"""
def __init__(self):
    self.sum = 0
    self.total = 0

def add(self, value, n):
    self.sum += value*n
    self.total += n

def value(self):
    return self.sum/self.total

def log(mode, epoch, loss_meter, accuracy_meter, best_perf=None):
"""
Вспомогательная функция для логирования
"""
print(
    f"[{mode}] Epoch: {epoch:.2f}. "
    f"Loss: {loss_meter.value():.2f}. "
    f"Accuracy: {100*accuracy_meter.value():.2f}%", end="\n")
    if best_perf:
        print(f"[best: {best_perf:.2f}]%", end="")

```

## Сверточная нейросеть с нуля

Вручную прописываем слои

```

model = nn.Sequential(
    nn.Conv2d(in_channels=3, out_channels=32, kernel_size=3,

```

```

        stride=1, padding=1),
        nn.ReLU(),
        nn.Conv2d(32, 64, kernel_size=3, stride=1, padding=1),
        nn.ReLU(),
        nn.MaxPool2d(2, 2), # output: 64 x 16 x 16

        nn.Conv2d(64, 128, kernel_size=3, stride=1, padding=1),
        nn.ReLU(),
        nn.Conv2d(128, 128, kernel_size=3, stride=1, padding=1),
        nn.ReLU(),
        nn.MaxPool2d(2, 2), # output: 128 x 8 x 8

        nn.Conv2d(128, 256, kernel_size=3, stride=1, padding=1),
        nn.ReLU(),
        nn.Conv2d(256, 256, kernel_size=3, stride=1, padding=1),
        nn.ReLU(),
        nn.MaxPool2d(2, 2), # output: 256 x 4 x 4

        nn.Flatten(),
        nn.Linear(256*28*28, 1024),
        nn.ReLU(),
        nn.Linear(1024, 512),
        nn.ReLU(),
        nn.Linear(512, 5))
model.to(device) # отправляем модель на девайс (GPU)

Sequential(
  (0): Conv2d(3, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1))
  (1): ReLU()
  (2): Conv2d(32, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1))
  (3): ReLU()
  (4): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
ceil_mode=False)
  (5): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1))
  (6): ReLU()
  (7): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1))
  (8): ReLU()
  (9): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
ceil_mode=False)
  (10): Conv2d(128, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1))
  (11): ReLU()
  (12): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1))
  (13): ReLU()
  (14): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
ceil_mode=False))

```

```
ceil_mode=False)
(15): Flatten(start_dim=1, end_dim=-1)
(16): Linear(in_features=200704, out_features=1024, bias=True)
(17): ReLU()
(18): Linear(in_features=1024, out_features=512, bias=True)
(19): ReLU()
(20): Linear(in_features=512, out_features=5, bias=True)
)
```

## Задаем параметры и функцию для обучения. Разбиваем датасет на train/validation

```
batch_size = 32
optimizer = torch.optim.Adam(params = model.parameters())
lr = 0.001
```

Разбиваем датасет на train и validation

Задаем dataloader'ы - объекты для итеративной загрузки данных и лейблов для обучения и валидации

```
train_set, val_set = torch.utils.data.random_split(dataset,
[len(dataset)-1000, 1000])
print('Размер обучающего и валидационного датасета: ', len(train_set),
len(val_set))
loaders = {'training': DataLoader(train_set, batch_size,
pin_memory=True,num_workers=2, shuffle=True),
           'validation':DataLoader(val_set, batch_size,
pin_memory=True,num_workers=2, shuffle=False)}
```

Размер обучающего и валидационного датасета: 3337 1000

Функция для подсчета Accuracy

```
def accuracy(outputs, labels):
    _, preds = torch.max(outputs, dim=1)
    return torch.tensor(torch.sum(preds == labels).item() /
len(preds))
```

Функция для обучения и валидации модели

```
def trainval(model, loaders, optimizer, epochs=10):
    """
    model: модель, которую собираемся обучать
    loaders: dict с dataloader'ами для обучения и валидации
    """
```

```

loss_meter = {'training': ValueMeter(), 'validation':
ValueMeter()}
accuracy_meter = {'training': ValueMeter(), 'validation':
ValueMeter()}

loss_track = {'training': [], 'validation': []}
accuracy_track = {'training': [], 'validation': []}

for epoch in range(epochs): # итерации по эпохам
    for mode in ['training', 'validation']: # обучение - валидация
        # считаем градиент только при обучении:
        with torch.set_grad_enabled(mode == 'training'):
            # в зависимости от фазы переводим модель в нужный
режим:
            model.train() if mode == 'training' else model.eval()
            for imgs, labels in tqdm(loaders[mode]):
                imgs = imgs.to(device) # отправляем тензор на GPU
                labels = labels.to(device)
                bs = labels.shape[0] # размер батча (отличается
для последнего батча в лоадере)

                preds = model(imgs) # forward pass - прогоняем
тензор с картинками через модель
                loss = F.cross_entropy(preds, labels) # считаем
функцию потерь
                acc = accuracy(preds, labels) # считаем метрику

                # храним loss и accuracy для батча
                loss_meter[mode].add(loss.item(), bs)
                accuracy_meter[mode].add(acc, bs)

                # если мы в фазе обучения
                if mode == 'training':
                    optimizer.zero_grad() # обнуляем прошлый
градиент
                    loss.backward() # делаем backward pass
(считаем градиент)
                    optimizer.step() # обновляем веса
# в конце фазы выводим значения loss и accuracy
log(mode, epoch, loss_meter[mode], accuracy_meter[mode])

# сохраняем результаты по всем эпохам
loss_track[mode].append(loss_meter[mode].value())
accuracy_track[mode].append(accuracy_meter[mode].value())
return loss_track, accuracy_track

```

# Обучаем базовую модель

Запускаем обучение на 10 эпох

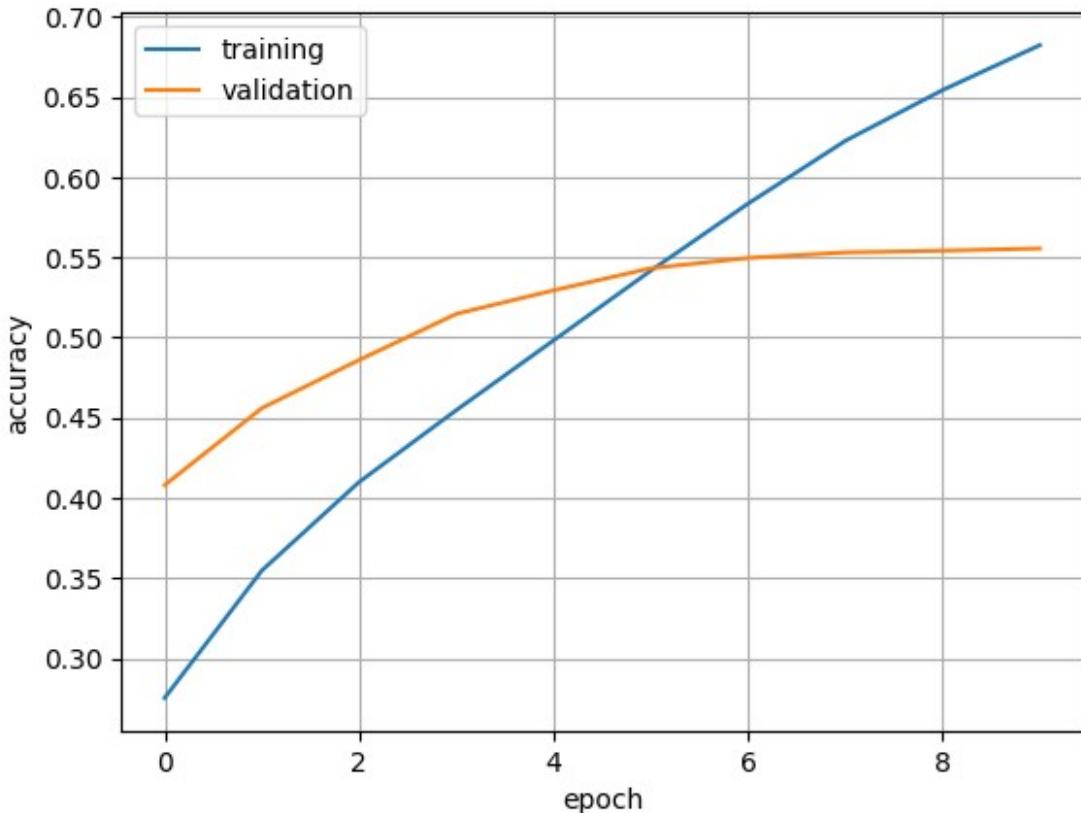
```
loss_track, accuracy_track = trainval(model, loaders, optimizer,
epochs=10)

100%|██████████| 105/105 [08:33<00:00, 4.89s/it]
[training] Epoch: 0.00. Loss: 1.58. Accuracy: 27.54%
100%|██████████| 32/32 [02:00<00:00, 3.76s/it]
[validation] Epoch: 0.00. Loss: 1.31. Accuracy: 40.80%
100%|██████████| 105/105 [00:33<00:00, 3.14it/s]
[training] Epoch: 1.00. Loss: 1.43. Accuracy: 35.48%
100%|██████████| 32/32 [00:07<00:00, 4.14it/s]
[validation] Epoch: 1.00. Loss: 1.23. Accuracy: 45.60%
100%|██████████| 105/105 [00:34<00:00, 3.08it/s]
[training] Epoch: 2.00. Loss: 1.33. Accuracy: 40.99%
100%|██████████| 32/32 [00:06<00:00, 4.73it/s]
[validation] Epoch: 2.00. Loss: 1.20. Accuracy: 48.60%
100%|██████████| 105/105 [00:34<00:00, 3.04it/s]
[training] Epoch: 3.00. Loss: 1.25. Accuracy: 45.47%
100%|██████████| 32/32 [00:06<00:00, 5.28it/s]
[validation] Epoch: 3.00. Loss: 1.15. Accuracy: 51.47%
100%|██████████| 105/105 [00:34<00:00, 3.07it/s]
[training] Epoch: 4.00. Loss: 1.17. Accuracy: 49.82%
100%|██████████| 32/32 [00:09<00:00, 3.41it/s]
[validation] Epoch: 4.00. Loss: 1.17. Accuracy: 52.94%
100%|██████████| 105/105 [00:34<00:00, 3.06it/s]
[training] Epoch: 5.00. Loss: 1.08. Accuracy: 54.17%
100%|██████████| 32/32 [00:07<00:00, 4.13it/s]
[validation] Epoch: 5.00. Loss: 1.19. Accuracy: 54.32%
```

```
100%|██████████| 105/105 [00:34<00:00, 3.06it/s]
[training] Epoch: 6.00. Loss: 0.99. Accuracy: 58.35%
100%|██████████| 32/32 [00:06<00:00, 4.70it/s]
[validation] Epoch: 6.00. Loss: 1.30. Accuracy: 54.96%
100%|██████████| 105/105 [00:34<00:00, 3.03it/s]
[training] Epoch: 7.00. Loss: 0.91. Accuracy: 62.26%
100%|██████████| 32/32 [00:06<00:00, 5.33it/s]
[validation] Epoch: 7.00. Loss: 1.43. Accuracy: 55.30%
100%|██████████| 105/105 [00:34<00:00, 3.07it/s]
[training] Epoch: 8.00. Loss: 0.84. Accuracy: 65.42%
100%|██████████| 32/32 [00:07<00:00, 4.19it/s]
[validation] Epoch: 8.00. Loss: 1.57. Accuracy: 55.41%
100%|██████████| 105/105 [00:34<00:00, 3.07it/s]
[training] Epoch: 9.00. Loss: 0.78. Accuracy: 68.22%
100%|██████████| 32/32 [00:07<00:00, 4.23it/s]
[validation] Epoch: 9.00. Loss: 1.78. Accuracy: 55.55%
```

```
from matplotlib import pyplot as plt
%matplotlib inline
plt.plot(accuracy_track['training'], label='training')
plt.plot(accuracy_track['validation'], label='validation')
plt.ylabel('accuracy')
plt.xlabel('epoch')
plt.grid()
plt.legend()

<matplotlib.legend.Legend at 0x7f7f90083a00>
```



```

import matplotlib.pyplot as plt
%matplotlib inline
import warnings
warnings.filterwarnings("ignore")

def predict_image(img, model):
    # Преобразование to a batch of 1
    xb = img.unsqueeze(0).to(device)
    # Получение прогнозов от модели
    yb = model(xb)
    # Выбираем индекс с наибольшей вероятностью
    _, preds = torch.max(yb, dim=1)
    # Получение метки класса
    return dataset.classes[preds[0].item()]

for i in range(1,10):
    img, label = val_set[i]
    plt.imshow(img.clip(0,1).permute(1, 2, 0))
    plt.axis('off')
    plt.title('Label: {}, Predicted: {}'.format(dataset.classes[label],predict_image(img, model)))
    plt.show()

```

Label: daisy, Predicted: daisy



Label: daisy, Predicted: daisy



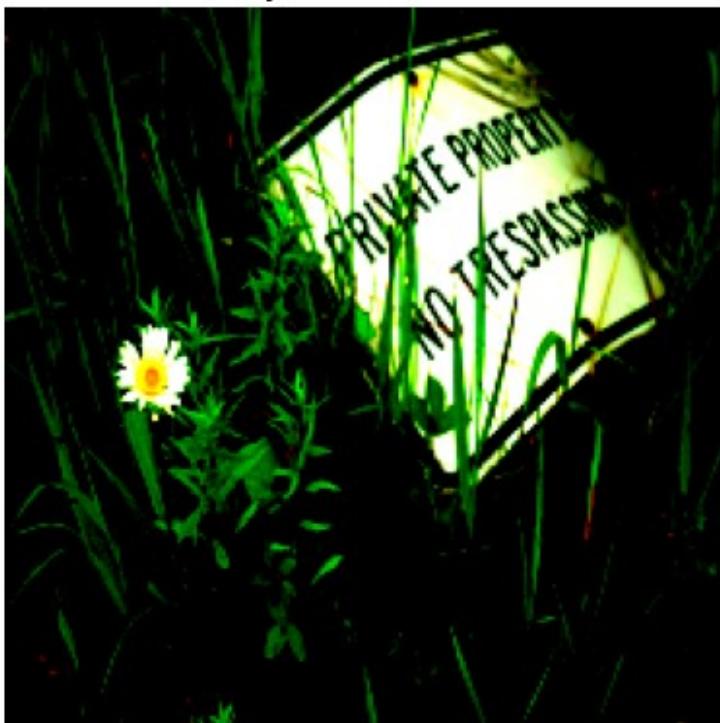
Label: sunflower, Predicted: rose



Label: tulip, Predicted: dandelion



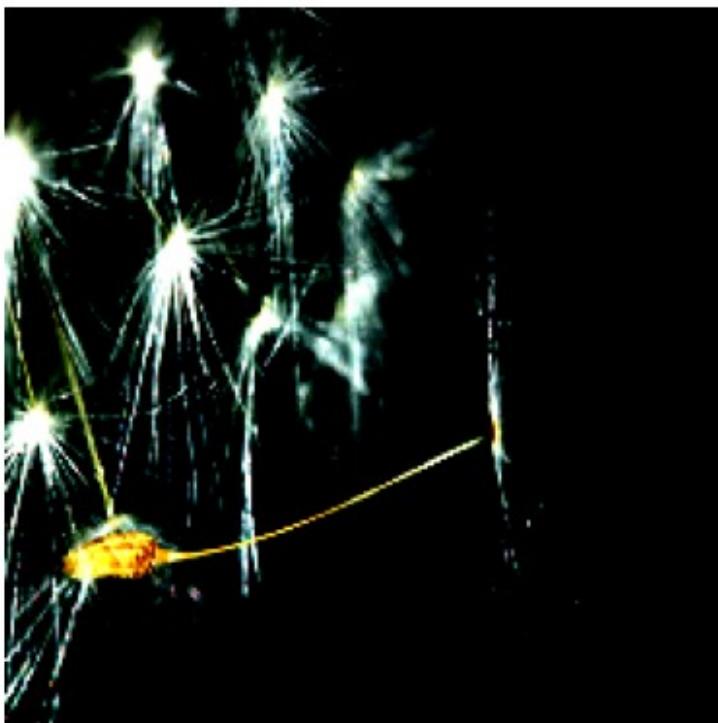
Label: daisy, Predicted: dandelion



Label: dandelion, Predicted: dandelion



Label: dandelion, Predicted: dandelion



Label: rose, Predicted: sunflower



Label: rose, Predicted: rose



## Практическое задание

В задние представлено логика выполнения с использование tensorflow/keras. Выполнять можно как с использованием tensorflow/keras, так и pytorch.

1. Необходимо обучить предобученную сверточную архитектуру для задач классификации цветов.

В выбранной Вами архитектуре также необходимо **разобраться** с основными её параметрами и принципами работы.

Посмотрите как использовать [модели в PyTorch](#) для классификации, выберите одну и используя transfer learning до-обучите модель на классификацию цветов. Чтобы это сделать замените \_\_\_\_\_ в ячейках ниже на работающий код.

1. Реализовать свою архитектуру, также как в разделе "Сверточная нейросеть с нуля".
2. Сравнить три архитектуры (из раздела "Сверточная нейросеть с нуля", предобученную сверточную архитектуру и свою архитектуру (из п. 2)). Визуализировать полученный результат сравнения.
1. Обучение предобученной сверточной архитектуры для задач классификации цветов

```
# Выберите модель resnet34 (как наиболее сбалансированную)
# из списка доступных в PyTorch моделей
# Указываем, что она модель должна быть предобучена!
model = torchvision.models.resnet34(pretrained=True)
model

Downloading: "https://download.pytorch.org/models/resnet34-
b627a593.pth" to /root/.cache/torch/hub/checkpoints/resnet34-
b627a593.pth
100%|██████████| 83.3M/83.3M [00:00<00:00, 138MB/s]

ResNet(
    (conv1): Conv2d(3, 64, kernel_size=(7, 7), stride=(2, 2),
padding=(3, 3), bias=False)
    (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    (relu): ReLU(inplace=True)
    (maxpool): MaxPool2d(kernel_size=3, stride=2, padding=1, dilation=1,
ceil_mode=False)
    (layer1): Sequential(
        (0): BasicBlock(
            (conv1): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
            (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
            (relu): ReLU(inplace=True)
            (conv2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
            (bn2): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        )
        (1): BasicBlock(
            (conv1): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
            (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
            (relu): ReLU(inplace=True)
            (conv2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
            (bn2): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        )
        (2): BasicBlock(
            (conv1): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
            (bn1): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
            (relu): ReLU(inplace=True)
            (conv2): Conv2d(64, 64, kernel_size=(3, 3), stride=(1, 1),
```

```
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(64, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    )
)
(layer2): Sequential(
    (0): BasicBlock(
        (conv1): Conv2d(64, 128, kernel_size=(3, 3), stride=(2, 2),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (downsample): Sequential(
            (0): Conv2d(64, 128, kernel_size=(1, 1), stride=(2, 2),
bias=False)
            (1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        )
    )
    (1): BasicBlock(
        (conv1): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    )
    (2): BasicBlock(
        (conv1): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    )
    (3): BasicBlock(
        (conv1): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
```

```
track_running_stats=True)
    (relu): ReLU(inplace=True)
    (conv2): Conv2d(128, 128, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
    (bn2): BatchNorm2d(128, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
)
)
(layer3): Sequential(
    (0): BasicBlock(
        (conv1): Conv2d(128, 256, kernel_size=(3, 3), stride=(2, 2),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (downsample): Sequential(
            (0): Conv2d(128, 256, kernel_size=(1, 1), stride=(2, 2),
bias=False)
            (1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        )
    )
    (1): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    )
    (2): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    )
)
(3): BasicBlock(  
)
```

```
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    )
    (4): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    )
    (5): BasicBlock(
        (conv1): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(256, 256, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(256, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    )
)
(layer4): Sequential(
    (0): BasicBlock(
        (conv1): Conv2d(256, 512, kernel_size=(3, 3), stride=(2, 2),
padding=(1, 1), bias=False)
        (bn1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (relu): ReLU(inplace=True)
        (conv2): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
        (bn2): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        (downsample): Sequential(
            (0): Conv2d(256, 512, kernel_size=(1, 1), stride=(2, 2),
bias=False)
            (1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
        )
    )
)
```

```

        )
    )
(1): BasicBlock(
    (conv1): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
    (bn1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    (relu): ReLU(inplace=True)
    (conv2): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
    (bn2): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
)
(2): BasicBlock(
    (conv1): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
    (bn1): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
    (relu): ReLU(inplace=True)
    (conv2): Conv2d(512, 512, kernel_size=(3, 3), stride=(1, 1),
padding=(1, 1), bias=False)
    (bn2): BatchNorm2d(512, eps=1e-05, momentum=0.1, affine=True,
track_running_stats=True)
)
)
(avgpool): AdaptiveAvgPool2d(output_size=(1, 1))
(fc): Linear(in_features=512, out_features=1000, bias=True)
)

# Функция для заморозки весов модели
def set_parameter_requires_grad(model):
    for param in model.parameters():
        param.requires_grad = False

set_parameter_requires_grad(model) # передаём модель в функцию для
"заморозки" градиента для предотвращения переобучения и сохранения
способности к обобщению признаков

model.fc = nn.Linear(
    in_features=model.fc.in_features, # число входов
    out_features=5 # число выходов (тк 5 классов)
) # Меняем последний слой модели для приложения к нашей задаче

# Проверим все ли сработало правильно, выведем веса, которые будут
обучаться
for name, param in model.named_parameters():
    if param.requires_grad:
        print(name)

```

```
fc.weight
fc.bias

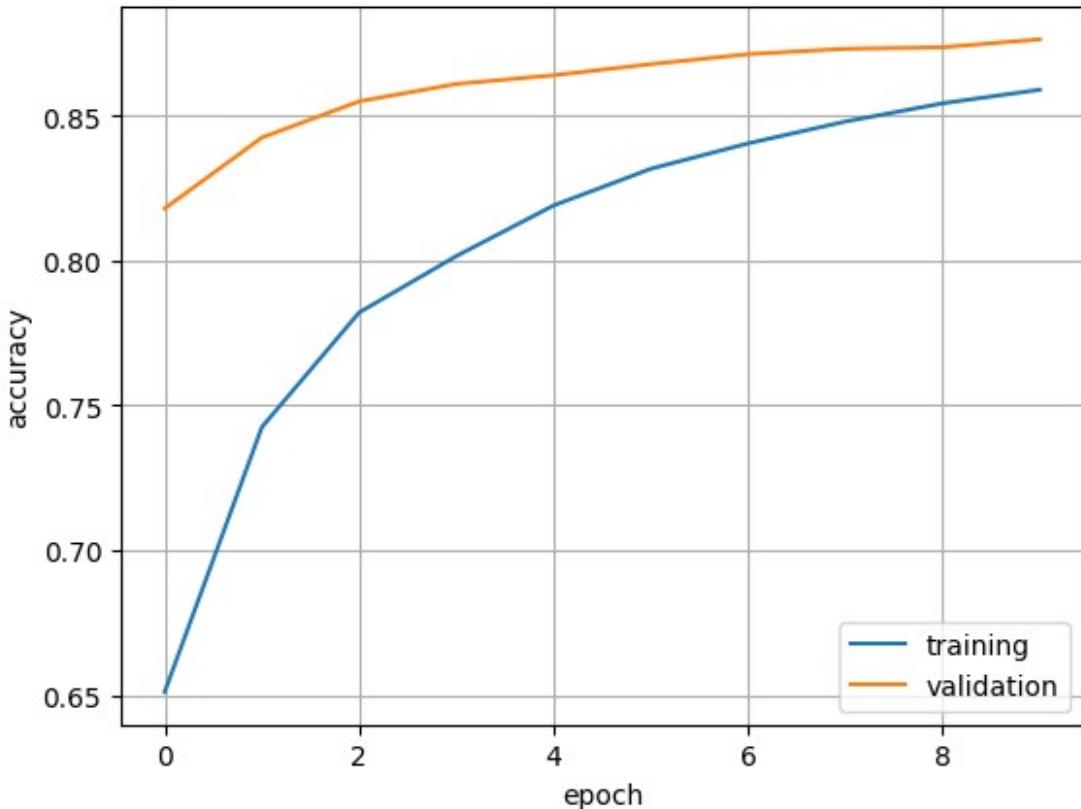
model.to(device) # Отправляем модель на GPU
optimizer = torch.optim.Adam(model.parameters(), lr=0.001) # алгоритм оптимизации
loss_track, accuracy_track = trainval(model, loaders, optimizer,
epochs=10)

100%|██████████| 105/105 [00:20<00:00, 5.14it/s]
[training] Epoch: 0.00. Loss: 0.98. Accuracy: 65.12%
100%|██████████| 32/32 [00:05<00:00, 5.92it/s]
[validation] Epoch: 0.00. Loss: 0.58. Accuracy: 81.80%
100%|██████████| 105/105 [00:21<00:00, 4.92it/s]
[training] Epoch: 1.00. Loss: 0.75. Accuracy: 74.26%
100%|██████████| 32/32 [00:05<00:00, 6.02it/s]
[validation] Epoch: 1.00. Loss: 0.51. Accuracy: 84.25%
100%|██████████| 105/105 [00:24<00:00, 4.24it/s]
[training] Epoch: 2.00. Loss: 0.64. Accuracy: 78.21%
100%|██████████| 32/32 [00:05<00:00, 5.63it/s]
[validation] Epoch: 2.00. Loss: 0.47. Accuracy: 85.50%
100%|██████████| 105/105 [00:21<00:00, 4.95it/s]
[training] Epoch: 3.00. Loss: 0.58. Accuracy: 80.16%
100%|██████████| 32/32 [00:05<00:00, 5.46it/s]
[validation] Epoch: 3.00. Loss: 0.45. Accuracy: 86.10%
100%|██████████| 105/105 [00:24<00:00, 4.32it/s]
[training] Epoch: 4.00. Loss: 0.53. Accuracy: 81.91%
100%|██████████| 32/32 [00:06<00:00, 4.59it/s]
[validation] Epoch: 4.00. Loss: 0.43. Accuracy: 86.40%
100%|██████████| 105/105 [00:22<00:00, 4.68it/s]
[training] Epoch: 5.00. Loss: 0.50. Accuracy: 83.17%
100%|██████████| 32/32 [00:05<00:00, 5.83it/s]
```

```
[validation] Epoch: 5.00. Loss: 0.42. Accuracy: 86.78%
100%|██████████| 105/105 [00:23<00:00, 4.46it/s]
[training] Epoch: 6.00. Loss: 0.47. Accuracy: 84.05%
100%|██████████| 32/32 [00:06<00:00, 5.06it/s]
[validation] Epoch: 6.00. Loss: 0.41. Accuracy: 87.13%
100%|██████████| 105/105 [00:23<00:00, 4.48it/s]
[training] Epoch: 7.00. Loss: 0.45. Accuracy: 84.80%
100%|██████████| 32/32 [00:07<00:00, 4.34it/s]
[validation] Epoch: 7.00. Loss: 0.40. Accuracy: 87.31%
100%|██████████| 105/105 [00:26<00:00, 3.93it/s]
[training] Epoch: 8.00. Loss: 0.43. Accuracy: 85.43%
100%|██████████| 32/32 [00:06<00:00, 5.30it/s]
[validation] Epoch: 8.00. Loss: 0.40. Accuracy: 87.37%
100%|██████████| 105/105 [00:20<00:00, 5.05it/s]
[training] Epoch: 9.00. Loss: 0.42. Accuracy: 85.90%
100%|██████████| 32/32 [00:06<00:00, 4.78it/s]
[validation] Epoch: 9.00. Loss: 0.39. Accuracy: 87.64%
```

```
plt.plot(accuracy_track['training'], label='training')
plt.plot(accuracy_track['validation'], label='validation')
plt.ylabel('accuracy')
plt.xlabel('epoch')
plt.grid()
plt.legend()

<matplotlib.legend.Legend at 0x7f7f55f705e0>
```



```
import matplotlib.pyplot as plt
%matplotlib inline
import warnings
warnings.filterwarnings("ignore")

def predict_image(img, model):
    xb = img.unsqueeze(0).to(device)
    yb = model(xb)
    _, preds = torch.max(yb, dim=1)
    return dataset.classes[preds[0].item()]

for i in range(1,10):
    img, label = val_set[i]
    plt.imshow(img.clip(0,1).permute(1, 2, 0))
    plt.axis('off')
    plt.title('Label: {}, Predicted: {}'.format(dataset.classes[label],predict_image(img, model)))
    plt.show()
```

Label: daisy, Predicted: daisy



Label: daisy, Predicted: daisy



Label: sunflower, Predicted: rose



Label: tulip, Predicted: tulip



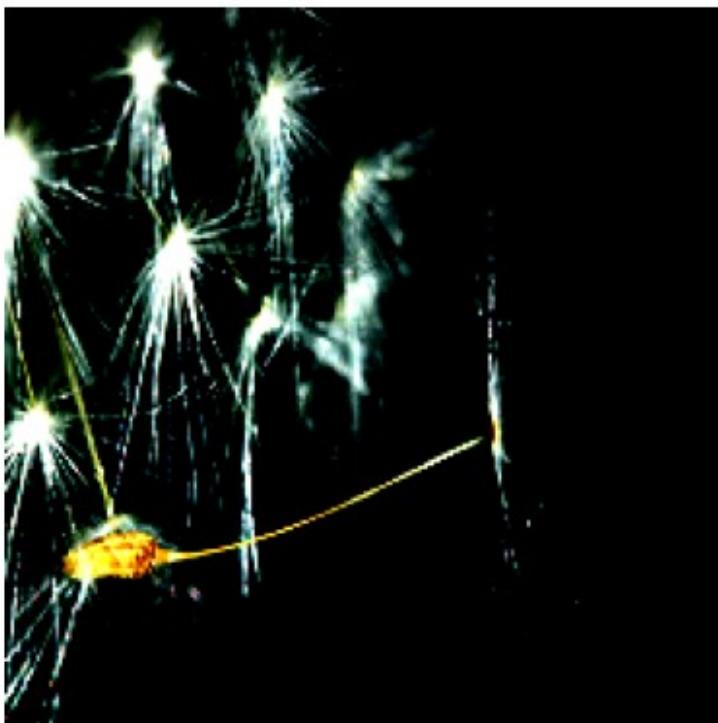
Label: daisy, Predicted: daisy



Label: dandelion, Predicted: dandelion



Label: dandelion, Predicted: dandelion



Label: rose, Predicted: sunflower



Label: rose, Predicted: rose



Также сохраним веса модели.

```
weights_fname = '/content/drive/My Drive/data/flower_model_koefs.pth'  
torch.save(model.state_dict(), weights_fname)
```

### 1. Своя архитектура

```
model = nn.Sequential(  
    # Свёрточный блок №1  
    nn.Conv2d(in_channels=3, out_channels=32, kernel_size=3, stride=1,  
    padding=1), # непосредственно свёртка с 3 входными каналами и 32  
    # выходными фильтрами  
    nn.ReLU(),  
    nn.MaxPool2d(kernel_size=2, stride=2), # уменьшение размера  
    # признаков в 2 раза  
  
    # Свёрточный блок №2  
    nn.Conv2d(in_channels=32, out_channels=64, kernel_size=3,  
    stride=1, padding=1),  
    nn.ReLU(),  
    nn.MaxPool2d(kernel_size=2, stride=2),  
  
    # Свёрточный блок №3  
    nn.Conv2d(in_channels=64, out_channels=128, kernel_size=3,  
    stride=1, padding=1),  
    nn.ReLU(),
```

```

nn.MaxPool2d(kernel_size=2, stride=2),
# # Преобразование вектора признаков и классификация
nn.Flatten(),
nn.Linear(128*28*28, 512), # Преобразование признаков
nn.ReLU(),
nn.Dropout(0.25), # Бьёмся с переобучением
nn.Linear(512, 5) # 5 classes for classification
)

model.to(device)

Sequential(
    (0): Conv2d(3, 32, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1))
    (1): ReLU()
    (2): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
ceil_mode=False)
    (3): Conv2d(32, 64, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1))
    (4): ReLU()
    (5): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
ceil_mode=False)
    (6): Conv2d(64, 128, kernel_size=(3, 3), stride=(1, 1), padding=(1,
1))
    (7): ReLU()
    (8): MaxPool2d(kernel_size=2, stride=2, padding=0, dilation=1,
ceil_mode=False)
    (9): Flatten(start_dim=1, end_dim=-1)
    (10): Linear(in_features=100352, out_features=512, bias=True)
    (11): ReLU()
    (12): Dropout(p=0.25, inplace=False)
    (13): Linear(in_features=512, out_features=5, bias=True)
)
batch_size = 32
optimizer = torch.optim.Adam(params = model.parameters())
lr = 0.001 # шаг обучения

```

Обучим, используя уже написанное `trainval`:

```

loss_track, accuracy_track = trainval(model, loaders, optimizer,
epoches=10)

100%|██████████| 105/105 [00:19<00:00, 5.30it/s]
[training] Epoch: 0.00. Loss: 1.37. Accuracy: 46.21%
100%|██████████| 32/32 [00:05<00:00, 5.95it/s]

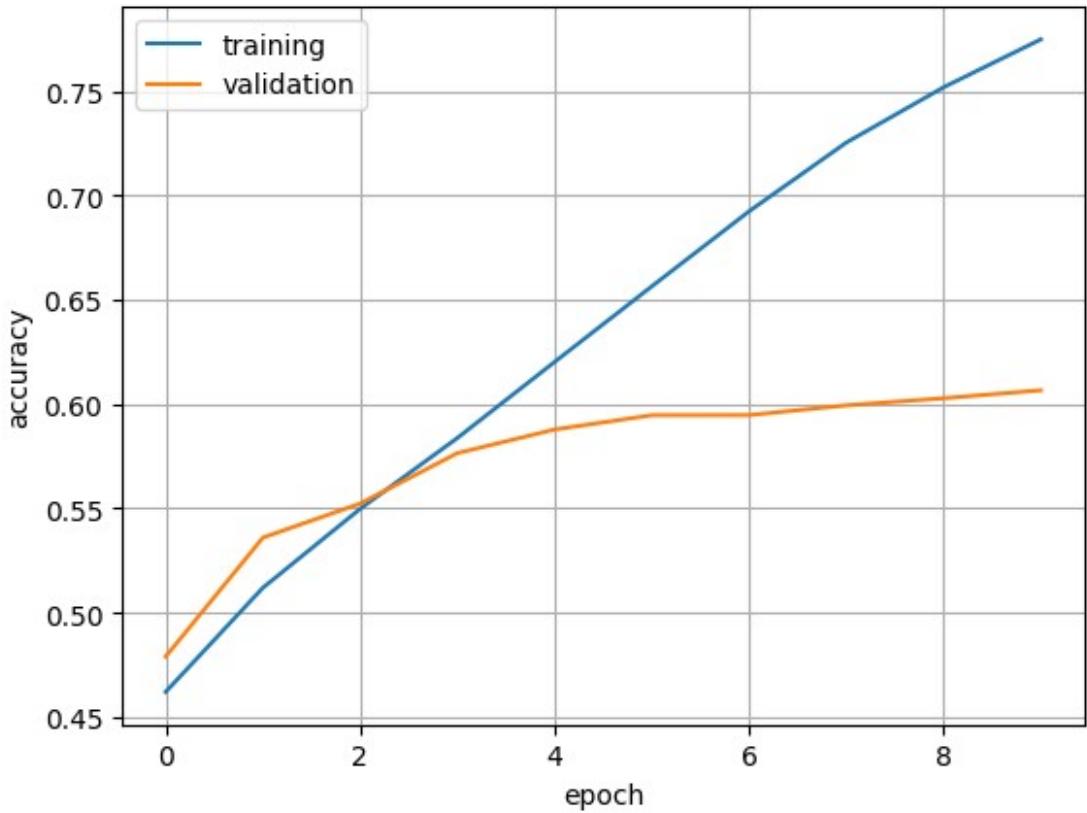
```

```
[validation] Epoch: 0.00. Loss: 1.21. Accuracy: 47.90%
100%|██████████| 105/105 [00:22<00:00, 4.70it/s]
[training] Epoch: 1.00. Loss: 1.22. Accuracy: 51.20%
100%|██████████| 32/32 [00:05<00:00, 5.50it/s]
[validation] Epoch: 1.00. Loss: 1.12. Accuracy: 53.60%
100%|██████████| 105/105 [00:21<00:00, 4.92it/s]
[training] Epoch: 2.00. Loss: 1.14. Accuracy: 54.98%
100%|██████████| 32/32 [00:05<00:00, 6.09it/s]
[validation] Epoch: 2.00. Loss: 1.08. Accuracy: 55.23%
100%|██████████| 105/105 [00:20<00:00, 5.11it/s]
[training] Epoch: 3.00. Loss: 1.06. Accuracy: 58.38%
100%|██████████| 32/32 [00:06<00:00, 4.75it/s]
[validation] Epoch: 3.00. Loss: 1.04. Accuracy: 57.65%
100%|██████████| 105/105 [00:25<00:00, 4.07it/s]
[training] Epoch: 4.00. Loss: 0.98. Accuracy: 62.02%
100%|██████████| 32/32 [00:05<00:00, 5.88it/s]
[validation] Epoch: 4.00. Loss: 1.03. Accuracy: 58.78%
100%|██████████| 105/105 [00:20<00:00, 5.20it/s]
[training] Epoch: 5.00. Loss: 0.89. Accuracy: 65.64%
100%|██████████| 32/32 [00:06<00:00, 4.63it/s]
[validation] Epoch: 5.00. Loss: 1.05. Accuracy: 59.47%
100%|██████████| 105/105 [00:20<00:00, 5.01it/s]
[training] Epoch: 6.00. Loss: 0.80. Accuracy: 69.24%
100%|██████████| 32/32 [00:07<00:00, 4.56it/s]
[validation] Epoch: 6.00. Loss: 1.11. Accuracy: 59.47%
100%|██████████| 105/105 [00:22<00:00, 4.76it/s]
[training] Epoch: 7.00. Loss: 0.72. Accuracy: 72.53%
100%|██████████| 32/32 [00:07<00:00, 4.23it/s]
```

```
[validation] Epoch: 7.00. Loss: 1.18. Accuracy: 59.94%
100%|██████████| 105/105 [00:21<00:00, 4.96it/s]
[training] Epoch: 8.00. Loss: 0.65. Accuracy: 75.18%
100%|██████████| 32/32 [00:07<00:00, 4.28it/s]
[validation] Epoch: 8.00. Loss: 1.25. Accuracy: 60.28%
100%|██████████| 105/105 [00:22<00:00, 4.62it/s]
[training] Epoch: 9.00. Loss: 0.59. Accuracy: 77.47%
100%|██████████| 32/32 [00:07<00:00, 4.29it/s]
[validation] Epoch: 9.00. Loss: 1.32. Accuracy: 60.66%

from matplotlib import pyplot as plt
plt.plot(accuracy_track['training'], label='training')
plt.plot(accuracy_track['validation'], label='validation')
plt.ylabel('accuracy')
plt.xlabel('epoch')
plt.grid()
plt.legend()

<matplotlib.legend.Legend at 0x7f7f40a0f340>
```

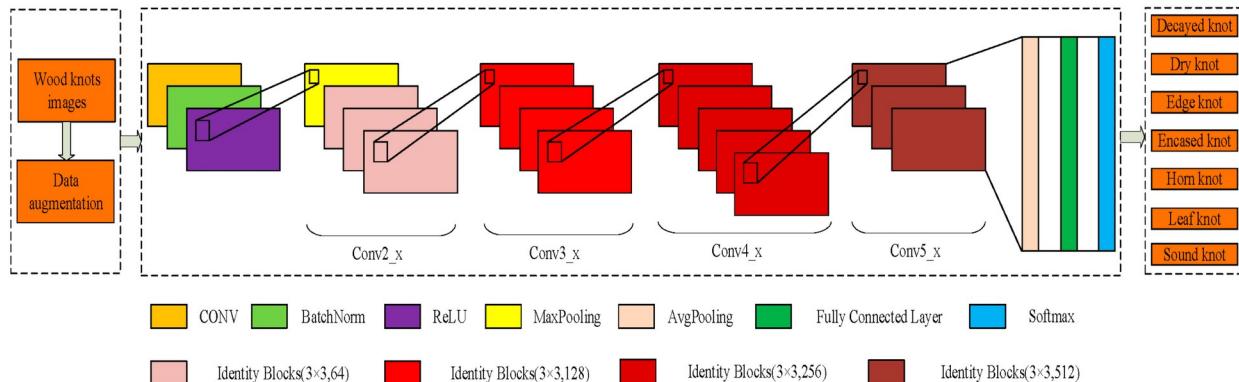


## 1. Сравнение и визуализация 3-х архитектур

Наилучшим образом себя показала предобученная на огромном числе данных модель с проработанной архитектурой. Что ж, видимо, в случае задач, которые уже были частично решены до этого, стоит использовать готовые модели (всё как всегда, хочешь решать часто встречающиеся практические задачи - используй готовые средства)

## Вопросы.

Архитектура предобученой resnet-34:



-глубокая сверточная нейронная сеть, состоящая из 34 слоёв, решает проблемы исчезающих градиентов обучения в очень глубоких сетях с помощью использования

остаточных блоков (позволяют пропускать информацию, что предотвращает исчезновение градиентов).

**Полносвязная сеть:**

- Каждая нейронная связь соединяет все нейроны текущего слоя с каждым нейроном следующего слоя.
- Игнорирует возможные зависимости в данных.

**Сверточная сеть:** \

- Использует свёртку, которая сканируют локальные области
- Использует локальные зависимости: каждый сверточный фильтр отвечает за выявление определенных шаблонов.

**Transfer learning** переносит веса, полученные при обучении модели в одной задаче, для решения другой. Такие модели, соответственно, называются предобученными нейронными сетями.

**Функция для заморозки весов** модели позволяет "заморозить" некоторые весы в процессе обучения, не позволяя им обновляться.

**Сверточный слой** применяет ядра свертки к локальным областям входных данных, чтобы выделить признаки.

**Пулинговый слой** уменьшает размер карт признаков, выбирая максимум (MaxPooling) или усредня значения (AveragePooling) в каждой области. Это снижает вычислительную сложность и делает модель более устойчивой к изменениям в данных, например, к смещениям.